

Thiết kế và kiểm định workflow trích xuất địa chỉ hai track cho YouTube Shorts tiếng Việt

Tóm tắt điều hành

Đối với YouTube Shorts, cách an toàn nhất không phải là “để model suy ra địa chỉ”, mà là xây một router cực hẹp cho **Track 1** và đẩy toàn bộ phần còn lại sang **Track 2**. Lý do là nguồn dữ liệu chính thức từ YouTube cho video công khai chủ yếu là metadata như `title`, `description`, `defaultAudioLanguage`, `duration`, trạng thái caption và các phần khác của `video` resource; trong khi structured data chuẩn cho trang video là `VideoObject`, còn trường `address` thuộc nhóm schema của `Place` / `PostalAddress`, nên trên native Shorts page khả năng có `JSON-LD address` hữu dụng cho địa chỉ quán là thấp. Vì vậy, nếu mục tiêu là “đúng địa chỉ thật sự” thay vì recall tối đa, Track 1 nên chỉ chấp nhận ba dạng bằng chứng: **prefix đúng chuẩn trong text**, `address` trong **JSON-LD**, hoặc **địa chỉ rõ ràng nằm trong** `description` với **format đủ mạnh**. Những gì đến từ OCR frame không có label, text bị hỏng cần repair, hoặc xác nhận dưới ngưỡng 0.90 đều phải bị đẩy sang Track 2. ¹

Một ràng buộc quan trọng khác là API chính thức của YouTube **không phải** là đường đi đầy đủ để lấy transcript công khai cho mọi video. `captions.list` chỉ cho biết caption track; còn `captions.download` yêu cầu quyền chỉnh sửa video. Nói cách khác, với Shorts công khai không thuộc quyền sở hữu của bạn, ASR fallback là thành phần gần như bắt buộc nếu muốn làm Track 2 tốt. ²

Bản đặc tả dưới đây ưu tiên **precision của Track 1** thay vì recall. Tôi đề xuất: dùng rule-based parsing + Gemini structured output ở chế độ JSON cho bước “clean only, no repair”; sau đó xác nhận bằng **Google Places Text Search + Place Details** với `FieldMask` tối thiểu, rồi chạy bước **Gemini confirm** để đưa ra quyết định cuối cùng. Chỉ khi **nguồn bằng chứng hợp lệ, không có repair**, và **Gemini confirm confidence ≥ 0.90** mới trả địa chỉ từ Track 1. ³

Bộ test seed 30 video ở cuối báo cáo được chia đều thành ba cụm: **10 video explicit-address**, **10 video implicit/inferred phải vào Track 2**, và **10 video borderline/ambiguous**. Các URL đều là Shorts (`/shorts/`) và được tuyển từ kết quả công khai trên web vào ngày 2026-06-24; các giá trị “Gemini confidence” trong bảng là **mô phỏng** vì quyền truy cập Gemini/Places API không được chỉ rõ. YouTube hiện cho phép Shorts dài tới 3 phút, nên giả định “Shorts only” là phù hợp với URL `/shorts/` trong tập seed này. ⁴

Giả định và nguyên tắc dữ liệu

Giả định nền của báo cáo này là: đầu vào luôn là **YouTube Shorts tiếng Việt hoặc nội dung đặt tại Việt Nam**, và hệ thống có thể gọi YouTube Data API, Google Places API, OCR, ASR, và Gemini; tuy nhiên quyền truy cập API key/thông tin quota cụ thể **không được chỉ định**, nên các điểm triển khai phụ thuộc API được mô tả ở mức đặc tả. Các mô tả về metadata video dựa trên `videos.list`, nơi `snippet` bao gồm các trường như `title`, `description`, `channelId`, `tags`, còn `contentDetails` và `status` cung cấp thêm duration/caption/privacy. Nếu cần phát hiện hoặc tìm video mới theo từ khoá, `search.list` là API discovery chính thức. ⁵

Với production routing, tôi khuyến nghị một nguyên tắc rất chặt: **chỉ dùng** `snippet.description` **lấy trực tiếp từ YouTube API hoặc HTML của chính Shorts page** để quyết định Track 1; không dùng Google SERP snippet làm nguồn quyết định. Lý do là snippet công cụ tìm kiếm có thể bị nhiễm địa chỉ footer hoặc địa chỉ doanh nghiệp của publisher hoàn toàn không liên quan đến quán trong video. Trong chính quá trình tuyển tập seed, tôi gặp nhiều ví dụ như một Shorts về món ăn lại bị snippet chèn địa chỉ toà soạn/publisher, hoặc snippet lẫn địa chỉ ngoài ngữ cảnh video. Đây là nguồn false positive rất nguy hiểm nếu dùng để route Track 1. 6

Ngoài ra, vì `captions.download` cần quyền chỉnh sửa video nên pipeline cho video công khai cần thiết kế theo hướng: **metadata trước, caption chính thức nếu có quyền, ASR fallback nếu không có quyền**. Đây là điểm khác biệt quan trọng giữa “phân tích video của mình” và “phân tích Shorts công khai trên Internet”. 2

Đặc tả routing hai track

Định nghĩa Track 1

Track 1 là đường đi “explicit address only”. Một video **chỉ được vào Track 1** nếu **ít nhất một** trong ba điều kiện sau đúng:

1. Có text chứa **prefix đúng chính tả** và đúng dấu hai chấm: `ĐC:` hoặc `Địa chỉ:` hoặc `Address:`.
2. Có `JSON-LD` structured data chứa trường `address`.
3. `YouTube description` có một cụm địa chỉ rõ ràng theo format: **số nhà + tên đường + quận/huyện/thành phố quận**; tức tối thiểu phải đủ mạnh để không phải suy diễn từ ngữ cảnh.

Mọi trường hợp sau **không được** vào Track 1:

- địa chỉ chỉ xuất hiện do **OCR frame không có label hợp lệ**;
- địa chỉ chỉ có được sau khi **Gemini “repair” text bị hỏng**;
- **Gemini confirm confidence < 0.90**;
- địa chỉ chỉ nằm trong **title, ASR**, hoặc **OCR** nhưng không có bằng chứng hợp lệ theo ba điều kiện trên. Đây là chính sách bảo thủ hơn nhưng phù hợp với mục tiêu precision cao. 7

Chuẩn hoá trước khi xét rule

Để giữ đúng tinh thần “Gemini clean only, no repair”, nên tách bước chuẩn hoá thành hai lớp:

Lớp deterministic trước model

Chỉ cho phép các biến đổi an toàn:

- Unicode normalization dạng NFKC.
- Chuẩn hoá khoảng trắng.
- Chuẩn hoá dấu `:` full-width về ASCII `:`.
- Chuẩn hoá dấu phẩy, ngoặc, gạch nối.
- Loại bullet/emoji bao quanh.
- Mở rộng viết tắt theo **closed lexicon** không mơ hồ, ví dụ `Q.` → `Quận`, `P.` → `Phường`, `TP.HCM` → `TP. Hồ Chí Minh`, `HCMC` → `TP. Hồ Chí Minh`, `HN` → `Hà Nội`.

Lớp Gemini clean

Gemini chỉ được phép:

- sắp xếp lại format về template chuẩn,
- giữ nguyên token gốc,
- đánh dấu `DAMAGED` nếu text có vẻ thiếu ký tự, rơi dấu, cắt cụt, hay OCR hỏng.

Gemini **không được** điền số nhà thiếu, đổi tên đường theo suy đoán, sửa ký tự “na ná”, hay suy luận quận từ ngữ cảnh. Structured output của Gemini hỗ trợ schema JSON, nên có thể ép model trả về object chặt chẽ thay vì văn bản tự do. ⁸

Rule phát hiện label và địa chỉ rõ ràng

Rule label exact-match nên chạy trên `title`, `description`, và text metadata visible của trang — nhưng **không chạy trên OCR**. Tiền xử lý trước bước match chỉ gồm NFKC + whitespace/colon normalization. Sau đó match **nguyên văn** ba prefix sau:

- `ĐC:`
- `Địa chỉ:`
- `Address:`

Không nên mở rộng baseline sang `dc:`, `dia chi:`, `Address :`, `Đ/C:` ở version đầu tiên; nếu muốn, hãy coi đó là một thí nghiệm recall riêng. Bằng cách này, đúng với yêu cầu “prefix exactly”.

Rule description-clear-format chỉ áp dụng cho `snippet.description` của YouTube. Rule này nên chấp nhận nếu parser thấy đủ ba thành phần:

- **house number**: ví dụ `39`, `284/3`, `129F/138/92`, `01`, `8D1`;
- **street name**: chuỗi tên đường có ít nhất 2 token chữ;
- **district/local admin**: ví dụ `Quận 1`, `Q.6`, `Hai Bà Trưng`, `Hoàn Kiếm`, `Thủ Đức`, `Bắc Từ Liêm`.

Nếu thiếu **số nhà** hoặc thiếu **district/local admin** trong clause quan sát được, không được cho vào Track 1. Đây là đường ranh quan trọng giữa “explicit” và “inferred”.

Pseudocode routing

```
ALLOWED_PREFIXES = ["ĐC:", "Địa chỉ:", "Address:"]
TRACK1_MIN_CONFIRM = 0.90

def route_short(video_url: str) -> dict:
    video_id = parse_video_id(video_url)

    yt = fetch_youtube_video(video_id) #
    videos.list(part=snippet,contentDetails,status)
    page = fetch_shorts_html(video_url) # raw HTML for JSON-LD + visible
    metadata text

    raw_title = yt.snippet.title or ""
    raw_desc = yt.snippet.description or ""
    visible_page_text = extract_visible_metadata_text(page) # not OCR
```

```

jsonld_objects = parse_all_jsonld(page)

# Step 0: build evidence candidates that are eligible for Track 1
candidates = []

# A. Exact label candidates from non-OCR text only
for source_name, text in [
    ("title", raw_title),
    ("description", raw_desc),
    ("page_text", visible_page_text),
]:
    norm_text = safe_pre_normalize(text) # NFKC + whitespace + colon
normalization only
    spans = find_exact_prefix_spans(norm_text, ALLOWED_PREFIXES)
    for span in spans:
        candidate = extract_address_after_prefix(norm_text, span)
        candidates.append({
            "source_type": "LABEL_TEXT",
            "source_name": source_name,
            "raw_candidate": candidate,
        })

# B. JSON-LD candidates
for obj in jsonld_objects:
    addr = find_schema_address(obj) # address / location.address /
itemReviewed.address
    if addr:
        candidates.append({
            "source_type": "JSONLD",
            "source_name": "jsonld",
            "raw_candidate": stringify_address(addr),
        })

# C. Clear-format description candidates only from snippet.description
for clause in split_description_into_clauses(raw_desc):
    if is_clear_address_clause(clause): # house no + street + district/
admin area
        candidates.append({
            "source_type": "CLEAR_DESCRIPTION",
            "source_name": "description",
            "raw_candidate": clause,
        })

# Step 1: attempt Track 1 confirmation
for c in dedupe_candidates(candidates):
    clean = gemini_clean_no_repair(c["raw_candidate"])

    if clean.status != "OK":
        continue
    if clean.disallowed_repair_detected:
        continue

```

```

places = confirm_with_google_places(
    normalized_address=clean.normalized_address,
    optional_shop_name=extract_shop_name(raw_title, raw_desc),
    language_code="vi",
    region_code="VN"
)

confirm = gemini_confirm_explicit_address(
    source_type=c["source_type"],
    raw_candidate=c["raw_candidate"],
    normalized_candidate=clean.normalized_address,
    shop_name=extract_shop_name(raw_title, raw_desc),
    places_candidates=places.top_k
)


if confirm.decision == "CONFIRMED" and confirm.confidence >=
TRACK1_MIN_CONFIRM:
    return {
        "track": "TRACK_1",
        "address": clean.normalized_address,
        "place_id": confirm.best_place_id,
        "confidence": confirm.confidence,
        "evidence_source": c["source_type"]
    }

# Step 2: fallback to Track 2
signals = collect_track2_signals(
    title=raw_title,
    description=raw_desc,
    ocr_frames=run_ocr_frames(video_url),
    asr_transcript=run_asr(video_url, language="vi-VN"),
)

return {
    "track": "TRACK_2",
    "signals": signals
}

```

Mermaid flowchart routing



Pipeline trích xuất dữ liệu

Nguồn dữ liệu và field nên lấy

Đầu tiên, từ URL `/shorts/{video_id}`, nên lấy `video_id` rồi gọi `videos.list`. Theo tài liệu chính thức, `videos.list` trả về các phần của resource video; `snippet` chứa title/description/channel/tags, và `contentDetails` chứa duration, trong khi `status` cho biết trạng thái cơ bản. Nếu cần discovery từ từ khoá thay vì từ URL đã biết, dùng `search.list`. ⁹

Bộ field tối thiểu nên đóng băng cho mỗi video gồm:

- `id`
- `snippet.title`
- `snippet.description`
- `snippet.channelTitle`
- `snippet.publishedAt`
- `snippet.defaultLanguage`
- `snippet.defaultAudioLanguage`
- `contentDetails.duration`
- `status.privacyStatus`
- `captions.list` để biết video có caption track hay không. ¹⁰

Song song, cần fetch HTML của chính Shorts page để parse toàn bộ `<script type="application/ld+json">`. Theo schema chuẩn, `address` là property của `Place` / `PostalAddress`, còn trang

video thường gắn `VideoObject`; vì vậy parser nên hỗ trợ tìm `address`, `location.address`, `itemReviewed.address`, nhưng phải chấp nhận thực tế rằng positive từ kênh này trên native Shorts sẽ rất hiếm. ⁷

OCR và ASR

Với OCR, Google Cloud Vision hỗ trợ `TEXT_DETECTION` và `DOCUMENT_TEXT_DETECTION`; ngoài ra còn hỗ trợ nhiều ngôn ngữ và có `language hint`. Tài liệu cũng lưu ý rằng language hint nhằm **cải thiện** nhận dạng, không phải để ép mô hình chỉ đọc một ngôn ngữ; nếu hint sai có thể làm kết quả tệ hơn. Với Shorts tiếng Việt, heuristics hợp lý là ưu tiên auto-detect, chỉ gợi ý `vi` khi overlay gần như toàn tiếng Việt. ¹¹

Về sampling, đây là một khuyến nghị kỹ thuật hơn là quy định từ tài liệu: với Shorts, nên lấy **1 fps baseline** và tăng dày hơn quanh scene change hoặc khi phát hiện vùng chữ ở 1/3 trên và 1/3 dưới khung hình. Lý do là text overlay, địa chỉ, CTA, hoặc nhãn quán thường nằm ở các dải này. OCR output cần lưu thêm:

- text block
- bbox
- frame timestamp
- mean conf nếu engine hỗ trợ
- cờ `has_allowed_prefix` nếu block chứa đúng `ĐC: / Địa chỉ: / Address: .`

Tuy nhiên, theo đặc tả router của báo cáo này, **OCR không phải nguồn vào Track 1**.

Với ASR, dùng locale `vi-VN`. Tài liệu Speech-to-Text khuyến nghị audio **16 kHz trở lên** nếu có thể và **tránh resampling** không cần thiết; danh sách ngôn ngữ hỗ trợ cũng xác nhận `vi-VN` có mặt. Vì caption tải xuống từ YouTube API bị giới hạn quyền, ASR fallback nên là chuẩn mặc định cho Track 2 nếu không quản lý video. ¹²

Rule nhận diện label

Rule label nên đơn giản và tuyệt đối:

```
(?:^|[\s\-\_|\u2022])(?P<label>ĐC:|Địa chỉ:|Address:)\s*(?P<body>.+)
```

Nhưng phải chạy sau `safe_pre_normalize`, không phải sau bước làm sạch “thông minh”. Nếu `body` sau label bị cắt cụt, lẫn nhiều quán, hoặc có dấu hiệu hỏng ký tự, vẫn xem là **không đủ điều kiện Track 1** cho đến khi có bằng chứng nguyên bản tốt hơn. Điều này trực tiếp thực thi yêu cầu “không repair”.

Signal set cho Track 2

Track 2 nên thu thập năm nhóm signal như yêu cầu:

- **Tên quán** từ `title`, `description`, OCR frame, và logo text nếu có.
- **Khu vực**: quận, thành phố, phường, cột mốc địa lý.
- **Món ăn/loại hình**: cơm tấm, bún bò, cà phê, lẩu, sushi, trà sữa...
- **ASR transcript** tiếng Việt.

- **OCR frames:** mọi text nhìn thấy, nhưng dùng như soft signal, không phải hard proof.

Từ đây, AI search nên sinh nhiều query có cấu trúc:

- `shop_name + district + city`
- `shop_name + dish + city`
- `dish + street + district`
- `spoken_phrase + area`
- `shop_name + alternative script/no-diacritic`

Rồi đưa từng query vào Places Text Search; nếu tên quán bị thiếu hoặc cắt, dùng thêm Places Autocomplete để lấy candidate trước khi gọi Place Details. Places Text Search được thiết kế để xử lý cả truy vấn mơ hồ và truy vấn không phải địa chỉ thuần. ¹³

Xác minh bằng Google Places và Gemini

Google Places confirm

Đối với Track 1, cách đơn giản nhất là gọi **Places Text Search (New)** với `textQuery` là `normalized_address`, có thể ghép thêm shop name nếu description chứa cả tên quán. Tài liệu Places yêu cầu chỉ định `FieldMask`; ở bước Text Search có thể yêu cầu tối thiểu `places.id, places.displayName, places.formattedAddress, places.primaryType`. Sau đó gọi **Place Details (New)** cho top candidate với `FieldMask` mở rộng hơn như `formattedAddress, displayName, businessStatus`, và nếu cần thì các trường chuyển địa điểm (`moved_place, moved_place_id`) để tránh xác nhận vào địa chỉ cũ đã di dời. ¹⁴

Tôi khuyến nghị chấm điểm deterministic trước khi đưa cho Gemini confirm:

```
score =
  0.40 * exact_house_number_match +
  0.20 * street_match +
  0.15 * district_match +
  0.10 * city_match +
  0.10 * shop_name_or_brand_match +
  0.05 * primary_type_match
```

Trong đó các thành phần có thể là nhị phân hoặc soft score 0..1. Sau đó áp các rule cứng:

- nếu evidence source không hợp lệ cho Track 1 → reject;
- nếu text cần repair → reject;
- nếu top1 và top2 quá sát nhau và khác quận → reject;
- nếu `businessStatus` /moved place cho thấy candidate cũ → theo `moved_place_id` hoặc reject.

Gemini clean và Gemini confirm

Gemini nên được ép sang JSON schema để tránh trả lời tự do. Structured outputs của Gemini hỗ trợ JSON schema subset, rất phù hợp cho hai tác vụ có format cứng như ở đây. ⁸

Input/Output đề xuất cho Gemini clean

```

{
  "input_schema": {
    "raw_candidate": "string",
    "source_type": "LABEL_TEXT | JSONLD | CLEAR_DESCRIPTION",
    "source_snippet": "string"
  },
  "output_schema": {
    "status": "OK | DAMAGED | NO_ADDRESS | MULTIPLE_ADDRESSES",
    "normalized_address": "string",
    "operations_applied": [
      "NFKC",
      "WHITESPACE_NORMALIZATION",
      "PUNCTUATION_NORMALIZATION",
      "SAFE_ABBREVIATION_EXPANSION",
      "DECORATION_REMOVAL"
    ],
    "disallowed_repair_detected": "boolean",
    "explanation": "string"
  }
}

```

Input/Output đề xuất cho Gemini confirm

```

{
  "input_schema": {
    "source_type": "LABEL_TEXT | JSONLD | CLEAR_DESCRIPTION",
    "raw_candidate": "string",
    "normalized_candidate": "string",
    "shop_name": "string",
    "places_candidates": [
      {
        "place_id": "string",
        "display_name": "string",
        "formatted_address": "string",
        "primary_type": "string",
        "business_status": "string"
      }
    ]
  },
  "output_schema": {
    "decision": "CONFIRMED | REJECT_TO_TRACK2 | UNSURE",
    "confidence": "number",
    "best_place_id": "string",
    "reason_codes": [
      "EXACT_HOUSE_NUMBER",
      "STREET_MATCH",
      "DISTRICT_MATCH",
      "CITY_MATCH",
      "NAME_MATCH",
    ]
  }
}

```

```

        "TYPE_MATCH",
        "SOURCE_NOT_ELIGIBLE",
        "REPAIR_NEEDED",
        "CONFLICTING_CANDIDATES",
        "TRUNCATED_EVIDENCE"
    ],
    "explanation": "string"
}
}

```

Rule cuối cùng:

- Nếu `decision != CONFIRMED` → Track 2.
- Nếu `confidence < 0.90` → Track 2.
- Nếu `clean.disallowed_repair_detected == true` → Track 2.
- Nếu nguồn gốc thực tế là OCR/title/ASR-only dù Places khớp đẹp → vẫn Track 2.

Cách này làm Gemini trở thành bộ “judge có giới hạn”, không phải công cụ tự bịa địa chỉ.

Bộ test 30 video Shorts

Tập dưới đây là **seed set để kiểm định router**, chia thành:

- **10 explicit-address**: nên vào Track 1.
- **10 implicit/inferred**: nên vào Track 2.
- **10 ambiguous/borderline**: nên giữ ở Track 2 trong baseline bảo thủ.

Lưu ý quan trọng:

- Cột **JSON-LD address** ở đây phản ánh **quan sát công khai có sẵn khi tuyển tập**, không phải kết quả crawl HTML đầy đủ từng video. Với native Shorts, tôi kỳ vọng hầu hết là **N**.
- Cột **OCR address present** nghĩa là **có bằng chứng công khai rằng địa chỉ nằm trên màn hình**; **N** nghĩa là **không quan sát được**, không khẳng định tuyệt đối không có.
- **Gemini confidence** là **mô phỏng** theo chính rubric của báo cáo này, vì quyền truy cập Gemini/Places API không được chỉ rõ.

Video URL	Title	Description excerpt	Label ĐC/Địa chỉ/ Address	JSON- LD address	OCR address present	Gemini conf.	Track đề xuất	Notes
https://www.youtube.com/shorts/ZDPXxZe4uEs	Banh Mi with NO Pate?! #vietnamfood #banhmi	Address: 39 Nguyen Trai, District 1, HCMC	Y	N	N	0.97	Track 1	Prefix Addre rõ ràng house numbe street - district

Video URL	Title	Description excerpt	Label ĐC/Địa chỉ/ Address	JSON- LD address	OCR address present	Gemini conf.	Track đề xuất	Notes
https://www.youtube.com/shorts/Hmd7A_1Xb44	Vietnamese Phở With... French Fries!??	Address: 52 Nguyen Cong Tru, Ward 19, Binh Thanh District, Ho Chi...	Y	N	N	0.96	Track 1	Prefix n address clause mạnh.
https://www.youtube.com/shorts/QL51CQ28vpg	Bún Đậu Hùng Cường Địa chỉ: Số 9, ngõ 56 Trần Quang Diệu...	Title chứa Địa chỉ: Số 9, ngõ 56 Trần Quang Diệu...	Y	N	N	0.97	Track 1	Explicit label n title. 1
https://www.youtube.com/shorts/aWjqL1wGzUE	Cà phê kem dẻo tại quán Cà Phê Cà Pháo...	Địa chỉ: CÀ PHÊ CÀ PHÁO 28 đường Thảo Diễn... Quận 2, TP.HCM	Y	N	N	0.96	Track 1	Có label exact v chỉ đủ mạnh.
https://www.youtube.com/shorts/TIfIqSNgcl8	Quán cà phê Nhật Bản giữa lòng Sài Gòn	Lạc Concept Địa chỉ: Hẻm 140 Trần Bình Trọng, Phường 2, Quận 5...	Y	N	N	0.95	Track 1	Có label exact t excerp 19
https://www.youtube.com/shorts/5Kt2X_L-zmU	Tiệm Chè Chang Hi drama	Chè Chang Hi Địa chỉ: 92C Cao Thắng, Phường 4, Quận 3...	Y	N	N	0.96	Track 1	Có label exact v chỉ rõ.

Video URL	Title	Description excerpt	Label ĐC/Địa chỉ/ Address	JSON- LD address	OCR address present	Gemini conf.	Track đề xuất	Notes
https://www.youtube.com/shorts/W5vVDobZ8VA	Quán bún bò sườn bẹ "size khủng", mỗi ngày bán 200 kg...	Tiệm bún bò Phú Hưng tại số 284/3 Chợ Lớn (Q.6, TP.HCM)	N	N	N	0.92	Track 1	Không prefix exact, nhưng description quan s được đ house number street - district
https://www.youtube.com/shorts/z_nTyA64-mo	Bún bò bình dân 3 tiếng bán sạch 70kg đồ ăn #shorts	... tại số 213B Phan Văn Khỏe (Q.6, TP.HCM)	N	N	N	0.92	Track 1	Đây là tốt cho "descri clear format" ²²
https://www.youtube.com/shorts/tYGQhyFdk6U	[FOOD REVIEW] BẾP HÀ NỘI NHỎ...	Địa chỉ các nơi trong video: BẾP HÀ NỘI NHỎ: 14 Trịnh Văn Cẩn... Q. 1, TP.HCM	N	N	N	0.93	Track 1	Không prefix e Địa c đơn lẻ, nhưng description có clau địa chỉ ²³
https://www.youtube.com/shorts/O2U5picQ9AU	[FOOD REVIEW] QUÁN SUSU ỐC-LẤU-NƯỚNG...	... QUÁN SUSU... 371/67A Hẻm 371 Trường Chinh, P. 14, Q. Tân Bình...	N	N	N	0.93	Track 1	Description đủ hou number street - district
https://www.youtube.com/shorts/s3QtciG_ILQ	The best and most reasonably priced beef noodle soup...	The address is pinned on the screen.	N	N	Y	0.76	Track 2	Chỉ biể chỉ nằ trên m hình; C only kh được v Track 1 ²⁵

Video URL	Title	Description excerpt	Label ĐC/Địa chỉ/ Address	JSON- LD address	OCR address present	Gemini conf.	Track đề xuất	Notes
https://www.youtube.com/shorts/o3An_wnTC1M	The first pho restaurant in Saigon...	address pinned on the screen	N	N	Y	0.74	Track 2	Cùng pattern OCR-on ²⁶
https://www.youtube.com/shorts/XC8FdZWQ40w	Mixed vermicelli at the University of Architecture	The address is pinned on the screen.	N	N	Y	0.73	Track 2	Không textual proof h lệ cho 1. ²⁷
https://www.youtube.com/shorts/5e3nN9TmaAo	Tai Ky Mi Gia - A Delicious 30+ Year Old Noodle Shop...	The address is pinned on the screen.	N	N	Y	0.75	Track 2	OCR/ address frame ²⁸
https://www.youtube.com/shorts/Vo2vRItp1d8	Thai Phien Fish Noodle Soup...	I have the address pinned on the screen.	N	N	Y	0.74	Track 2	Không được promo lên Tra ²⁹
https://www.youtube.com/shorts/zGrWnb9C84c	Anh Minh Quan - A really delicious Chinese restaurant...	The address is pinned on the screen.	N	N	Y	0.75	Track 2	Quy tắc trừ OC only. ³⁰
https://www.youtube.com/shorts/avLPIQA7w0I	NỘM LONG VI DUNG - 23 Hồ Hoàn Kiếm, Quận Hoàn Kiếm, Hà Nội	Title chứa full address-like string	N	N	N	0.88	Track 2	Địa chỉ trong t baselin này kh cho titl only và Track 1 ³¹
https://www.youtube.com/shorts/W8ewx2gZqU4	BÁNH MÌ CHẢ NÓNG DỪNG HẠNH...	Quận Hai Bà Trưng, Thành phố Hà Nội. Giờ phục vụ...	N	N	N	0.83	Track 2	Có loca nhưng chưa th house number trong b chứng quan s được.

Video URL	Title	Description excerpt	Label ĐC/Địa chỉ/ Address	JSON- LD address	OCR address present	Gemini conf.	Track đề xuất	Notes
https://www.youtube.com/shorts/G9hPnWIpXXA	ỐC CAY CÔ THỦY...	Quán ốc 107 Thuy Khuê là địa chỉ quen thuộc...	N	N	N	0.86	Track 2	Có stre numbe nhưng thiếu district trong eviden quan s được.
https://www.youtube.com/shorts/jsj8bkSfC-c	"Thiên đường" đồ ăn sẵn khu phố cổ Hà Nội	Chợ Hàng Bè... địa chỉ quen thuộc...	N	N	N	0.68	Track 2	Area-o không địa chỉ explicit 34
https://www.youtube.com/shorts/ABu9EuMbb5A	Bún đậu mắm tôm #shorts	... tại địa chỉ 216 Hoàng Ngân, Hà Nội...	N	N	N	0.88	Track 2	Border có số n đường nhưng thiếu district trong eviden hiện th 35
https://www.youtube.com/shorts/WDckuulKB6g	Nem cua biển #shorts	Có một địa chỉ trên phố Giảng Võ...	N	N	N	0.80	Track 2	Border có stre nhưng thiếu h numbe 36
https://www.youtube.com/shorts/Gv5Kcox1gIQ	Mì vẫn thần #shorts	... có một quán ăn nhỏ... địa chỉ mỳ ...	N	N	N	0.82	Track 2	Border excerp cắt, kh đủ eviden nguyên bản. 3

Video URL	Title	Description excerpt	Label ĐC/Địa chỉ/ Address	JSON- LD address	OCR address present	Gemini conf.	Track đề xuất	Notes
https://www.youtube.com/shorts/mVz0DzKh7PM	Khó tin mà có thật đĩa CƠM GÀ siêu bự...	Địa chỉ: 114 Lê Thị Riêng, Quận ...	Y	N	N	0.87	Track 2	Border có label nhưng evidenc hiện th truncat không được r để lên 1. 38
https://www.youtube.com/shorts/NUgkUZ5XzPQ	Bật mí QUÁN CÀ PHÊ dành riêng cho hssv Thủ Đức...	Ăn Coffee Địa chỉ: số 43, Đường 30 ...	Y	N	N	0.86	Track 2	Border label c nhưng chỉ qua sát đư chưa đ đủ. 39
https://www.youtube.com/shorts/9BZ8f4B300E	[FOOD REVIEW] BÚN BÒ THỐ ĐÁ HOA DÓ ĐÀ LẠT...	Địa chỉ các nơi trong video: ...	N	N	N	0.84	Track 2	Border biết descri có bloc chỉ, nh excerpt công k không để xác nhận.
https://www.youtube.com/shorts/YD9cbYPIEpY	[FOOD REVIEW] LẦN ĐẦU TRẢI NGHIỆM THE 350F...	Địa chỉ các nơi trong video ...	N	N	N	0.84	Track 2	Border do evic truncat 41

Video URL	Title	Description excerpt	Label ĐC/Địa chỉ/ Address	JSON- LD address	OCR address present	Gemini conf.	Track đề xuất	Notes
https://www.youtube.com/shorts/LtbNR1HpOgw	[FOOD REVIEW] ĐI ĂN QUÁN BÚN CHẢ 29...	Địa chỉ các nơi trong video: ...	N	N	N	0.85	Track 2	Border product crawler thể reclass nếu full descrip đầy đủ seed baselin giữ ở T 42
https://www.youtube.com/shorts/qr_LgJ2N3Ro	Món phở ăn kèm cơm nguội ở Hà Nội...	... ở phố Nguyễn Du (quận Hai Bà Trưng...)	N	N	N	0.83	Track 2	Border có stre district nhưng chưa th house numbe 43
https://www.youtube.com/shorts/eM_uLz7n0Qs	Hé lộ bí quyết làm nên món bún chả Hồng...	... tại địa chỉ số 1 Đông Thái, Chợ Gạo...	N	N	N	0.87	Track 2	Border có số n đường nhưng excerpt chưa đ district rõ ràng 44

Một điểm rất đáng chú ý từ bảng seed là có khá nhiều video “suýt explicit” nhưng **không nên** cho qua Track 1 ở baseline, chỉ vì thiếu đúng một thành phần: số nhà, district, hoặc nguyên văn description bị truncate. Đây chính là nơi các hệ thống extraction thường mắc lỗi “repair cho có vẻ đúng”. Trong workflow bạn đang hướng tới, các ca này phải bị demote sang Track 2 một cách có chủ ý. 45

Kế hoạch đánh giá

Nhãn vàng và protocol

Mỗi video trong benchmark nên có các trường nhãn vàng sau:

- gold_track1_eligible : true/false
- gold_address

- `gold_evidence_type`: `LABEL_TEXT` | `JSONLD` | `CLEAR_DESCRIPTION` | `OCR_ONLY` | `TITLE_ONLY` | `AMBIGUOUS`
- `gold_place_id` nếu xác định được
- `notes` giải thích vì sao reject/accept

Với seed set 30 video, nên dùng như **smoke test** cho router. Để đánh giá ổn định, tôi khuyến nghị nói lên ít nhất 150–300 Shorts sau khi đã có crawler ổn định, vì 30 video chỉ đủ phát hiện lỗi logic rất rõ. Đây là khuyến nghị phương pháp luận, không phải ràng buộc từ API.

Metric cốt lõi

Metric quan trọng nhất không phải chỉ là “address extraction accuracy”, mà là **Track 1 acceptance quality**:

- **Track 1 precision**

$$\text{TP_accept} / (\text{TP_accept} + \text{FP_accept})$$

Đây là metric số một. Nếu Track 1 sai, workflow mất mục tiêu.

- **Track 1 recall**

$$\text{TP_accept} / \text{all_gold_track1_eligible}$$

Hữu ích nhưng xếp sau precision.

- **Wrong-address rate among accepted Track 1**

$$\text{accepted_but_wrong_address} / \text{all_accept_track1}$$

Đây là chỉ số nên giữ cực thấp.

- **Leakage rate**

Tỷ lệ video `OCR_ONLY`, `TITLE_ONLY`, `AMBIGUOUS` bị lỗi route vào Track 1.

- **Component accuracy** cho địa chỉ accepted

house number / street / district / city.

Một baseline hợp lý cho hệ thống production là:

- Track 1 precision mục tiêu: ≥ 0.98
- Wrong-address rate trong Track 1: ≤ 0.02
- Leakage từ OCR-only sang Track 1: **0**
- Recall của Track 1: chấp nhận thấp hơn miễn precision rất cao.

Với bài toán này, precision của Track 1 quan trọng hơn recall vì Track 2 vẫn còn cơ hội suy luận tiếp.

Ngưỡng

Ngưỡng `Gemini confirm confidence = 0.90` là hợp lý cho baseline bảo thủ vì:

- Places Text Search có thể xử lý query mơ hồ, nhưng ambiguity vẫn tồn tại;
- Place Details cần field-mask và có thể cho thông tin moved/closed place;
- JSON structured output giúp mô hình trả format ổn định hơn, nhưng không biến model thành ground truth. ⁴⁶

Tôi khuyến nghị thêm một rule phụ: dù Gemini trả `0.90+`, nếu code phát hiện evidence source là `OCR_ONLY`, `TITLE_ONLY`, hoặc `TRUNCATED_EVIDENCE`, vẫn phải override về Track 2. Nghĩa là confidence **không được phép** đánh bại evidence policy.

Rủi ro triển khai và cách giảm thiểu

Rủi ro lớn nhất là **nhầm địa chỉ ngoài ngữ cảnh video**. Trong thực tế tuyển seed, nhiều snippet công khai của Shorts đã lẫn địa chỉ publisher hoặc địa chỉ cửa hàng không liên quan, đặc biệt với kênh báo chí hoặc video tổng hợp. Nếu bạn dùng web snippet thay cho `snippet.description` nguyên bản của YouTube, Track 1 sẽ bị false positive rất nhanh. Giảm thiểu bằng cách: chỉ route từ **metadata lấy trực tiếp từ YouTube API hoặc raw Shorts HTML**, lưu snapshot description thô, và log provenance của từng candidate address. ⁶

Rủi ro thứ hai là **“repair creep”**: vì model rất giỏi điền chỗ trống, nên chỉ cần để prompt lỏng một chút là Gemini sẽ tự sửa `Le Thi Rieng` thành `Lê Thị Riêng`, tự gán quận còn thiếu, hoặc nối nhiều nhánh cửa hàng thành một địa chỉ mới trông rất hợp lý. Cách giảm thiểu là ép structured output, lưu `operations_applied`, và có validator hậu kiểm: nếu chuỗi output chứa token mới không nằm trong closed lexicon mở rộng an toàn, gán cờ `disallowed_repair_detected = true`. ⁸

Rủi ro thứ ba là **caption/transcript ảo tưởng**. Vì YouTube API không cho bạn tự do tải caption công khai của người khác chỉ bằng Data API, nhiều đội vô tình thiết kế pipeline dựa trên giả định “lúc nào cũng có transcript chính thức”. Thực tế không phải vậy. Giảm thiểu bằng cách làm rõ từ đầu: Track 2 luôn có ASR fallback, và transcript từ YouTube chỉ là optional enhancement khi bạn có quyền phù hợp. ²

Rủi ro thứ tư là **địa điểm di dời hoặc nhiều chi nhánh**. Places có thể trả place đã chuyển (`moved_place`, `moved_place_id`) hoặc nhiều candidate tên giống nhau. Nếu không kiểm house number/district và không chấm điểm uniqueness, bạn có thể xác nhận nhầm chi nhánh. Giảm thiểu bằng Place Details hậu kiểm, ưu tiên candidate có khớp house number + street + district, và reject nếu top-1/top-2 quá sát nhau ở khác quận. ⁴⁷

Rủi ro cuối cùng là **borderline data drift**: creator sửa description sau khi bạn đã benchmark. Vì vậy benchmark phải được “đóng băng” theo snapshot gồm `title`, `description`, HTML, OCR text, ASR transcript, timestamp crawl, và cả danh sách Places candidates tại thời điểm chấm. Nếu không, cùng một video có thể nhảy nhóm từ Track 2 sang Track 1 chỉ vì description được bổ sung sau đó.

¹ ⁵ ¹⁰ <https://developers.google.com/youtube/v3/docs/videos>

<https://developers.google.com/youtube/v3/docs/videos>

² Captions: list | YouTube Data API

https://developers.google.com/youtube/v3/docs/captions/list?utm_source=chatgpt.com

³ ¹³ ¹⁴ ⁴⁶ Text Search (New) | Places API

https://developers.google.com/maps/documentation/places/web-service/text-search?utm_source=chatgpt.com

⁴ Understand three-minute YouTube Shorts

https://support.google.com/youtube/answer/15424877?hl=en&utm_source=chatgpt.com

⁶ Dê tái chanh Ninh Bình lọt top 36 món thịt dê ngon nhất thế ...

https://www.youtube.com/shorts/qc92TYgGZBk?utm_source=chatgpt.com

- 7 address - Schema.org Property
https://schema.org/address?utm_source=chatgpt.com
- 8 Structured outputs - Interactions API - Google AI for Developers
https://ai.google.dev/gemini-api/docs/structured-output?utm_source=chatgpt.com
- 9 Videos: list | YouTube Data API
https://developers.google.com/youtube/v3/docs/videos/list?utm_source=chatgpt.com
- 11 Detect and extract text from images | Cloud Vision API
https://docs.cloud.google.com/vision/docs/ocr?utm_source=chatgpt.com
- 12 Best practices | Cloud Speech-to-Text
https://docs.cloud.google.com/speech-to-text/docs/best-practices?utm_source=chatgpt.com
- 15 Banh Mi with NO Pate?! #vietnamfood #banhmi
https://www.youtube.com/shorts/ZDPXxZe4uEs?utm_source=chatgpt.com
- 16 #shorts Vietnamese Phở With... French Fries!??
https://www.youtube.com/shorts/Hmd7A_1Xb44?utm_source=chatgpt.com
- 17 Bún Đậu Hùng Cường Địa chỉ: Số 9, ngõ 56 Trần Quang Diệu ...
https://www.youtube.com/shorts/QL51CQ28vpg?utm_source=chatgpt.com
- 18 Cà phê kem dẻo tại quán Cà Phê Cà Pháo của ca sĩ Đàm ...
https://www.youtube.com/shorts/aWjqL1wGzUE?utm_source=chatgpt.com
- 19 Quán cà phê Nhật Bản giữa lòng Sài Gòn | Thánh Rivi
https://www.youtube.com/shorts/TIfIqSNGcl8?utm_source=chatgpt.com
- 20 https://www.youtube.com/shorts/5Kt2X_L-zmU
https://www.youtube.com/shorts/5Kt2X_L-zmU
- 21 <https://www.youtube.com/shorts/W5vVDobZ8VA>
<https://www.youtube.com/shorts/W5vVDobZ8VA>
- 22 https://www.youtube.com/shorts/z_nTyA64-mo
https://www.youtube.com/shorts/z_nTyA64-mo
- 23 <https://www.youtube.com/shorts/tYGQhyFdk6U>
<https://www.youtube.com/shorts/tYGQhyFdk6U>
- 24 [FOOD REVIEW] QUÁN SUSU ỐC-LẨU-NƯỚNG | QUÁN ỐC ...
https://www.youtube.com/shorts/O2U5picQ9AU?utm_source=chatgpt.com
- 25 https://www.youtube.com/shorts/s3Qtcig_ILQ
https://www.youtube.com/shorts/s3Qtcig_ILQ
- 26 https://www.youtube.com/shorts/o3An_wnTC1M
https://www.youtube.com/shorts/o3An_wnTC1M
- 27 <https://www.youtube.com/shorts/XC8FdZWQ40w>
<https://www.youtube.com/shorts/XC8FdZWQ40w>
- 28 <https://www.youtube.com/shorts/5e3nN9TmaAo>
<https://www.youtube.com/shorts/5e3nN9TmaAo>
- 29 <https://www.youtube.com/shorts/Vo2vRItp1d8>
<https://www.youtube.com/shorts/Vo2vRItp1d8>
- 30 <https://m.youtube.com/shorts/zGrWnb9C84c>
<https://m.youtube.com/shorts/zGrWnb9C84c>

- 31 <https://www.youtube.com/shorts/avLPIQA7w0I>
<https://www.youtube.com/shorts/avLPIQA7w0I>
- 32 <https://www.youtube.com/shorts/W8ewx2gZqU4>
<https://www.youtube.com/shorts/W8ewx2gZqU4>
- 33 <https://www.youtube.com/shorts/G9hPnWIpXXA>
<https://www.youtube.com/shorts/G9hPnWIpXXA>
- 34 "Thiên đường" đồ ăn sẵn khu phố cổ Hà Nội #shorts ...
https://www.youtube.com/shorts/jsj8bk5fC-c?utm_source=chatgpt.com
- 35 45 <https://m.youtube.com/shorts/ABu9EuMbb5A>
<https://m.youtube.com/shorts/ABu9EuMbb5A>
- 36 <https://www.youtube.com/shorts/WDckuulKB6g>
<https://www.youtube.com/shorts/WDckuulKB6g>
- 37 Mì vằn thắn #shorts
https://www.youtube.com/shorts/Gv5Kcox1gIQ?utm_source=chatgpt.com
- 38 Khó tin mà có thật đĩa CƠM GÀ siêu bự chỉ 40K ngay trung ...
https://www.youtube.com/shorts/mVz0DzKh7PM?utm_source=chatgpt.com
- 39 Bật mí QUÁN CÀ PHÊ dành riêng cho hssv Thủ Đức không ...
https://www.youtube.com/shorts/NUgkUZ5XzPQ?utm_source=chatgpt.com
- 40 [FOOD REVIEW] BÚN BÒ THỐ ĐÁ HOA DÓ ĐÀ LẠT | EMILYNA ...
https://www.youtube.com/shorts/9BZ8f4B300E?utm_source=chatgpt.com
- 41 [FOOD REVIEW] LẦN ĐẦU TRẢI NGHIỆM THE 350F DESSERT ...
https://www.youtube.com/shorts/YD9cbYPIEpY?utm_source=chatgpt.com
- 42 <https://www.youtube.com/shorts/LtbNR1HpOgw>
<https://www.youtube.com/shorts/LtbNR1HpOgw>
- 43 https://www.youtube.com/shorts/qR_LgJ2N3Ro
https://www.youtube.com/shorts/qR_LgJ2N3Ro
- 44 https://www.youtube.com/shorts/eM_uLz7n0Qs
https://www.youtube.com/shorts/eM_uLz7n0Qs
- 47 Place Details (New) | Places API
https://developers.google.com/maps/documentation/places/web-service/place-details?utm_source=chatgpt.com